Mnemos · 实现机制清单（v1.7.0）

这份文档只列有哪些机制：每条说清 保证什么 / 怎么保证 / 边界在哪。

数值以 00-事实表-v1.7.0.md 为准；代码结构见《模块与功能实现》。

阅读方式：先看“保证”和“边界”两列就够了；“怎么保证”是给想确认它不是空话的人看的。

一、记忆的存与取

机制	保证什么	怎么保证	边界
记忆是外部存储	上下文只留当前工作集，长期知识在文件里；换会话、换工作区都能接着用	写入/召回都是显式工具调用；数据按 profile 定位（与当前目录无关），所有会话共用同一份	没写下来就等于没发生；不同 profile 之间默认不共享
写入安全	不丢更新、不复活已删记录	写前重读磁盘 + 三方合并 + 文件锁 + 删除留墓碑	只对同一份数据文件有效；多机共用未验证
三种召回模式	固定身份在场；任务可按需取证；工具后还能搭车给线索	① 固定注入（自传体）；② 任务激活（模型主动 recall/open）；③ 联想激活（fansearch 工具后附注候选 id + 摘要片段，不自动 open、不保证相关）	①有预算；②依赖模型判断；③是实验性/早期质量，不是召回承诺
两段式取用	先用便宜方式判断相关，再为真正需要的付全文成本	recall 返回摘要 + id；需要细节时 open(id)	写了但召不回是可能的
分层与归档	记忆库不无限膨胀，且可回溯	热/冷分层、闲置降权；archiveSession 每 scope 单份、archive 冷存、原始记录转冷	存档默认不进召回；历史巨物按前缀/体积识别后默认过滤，不删除
真删除	隐私内容可删干净	硬删除 + 墓碑（防止旧副本写回）	不可恢复

二、判断的身份与留痕

机制	保证什么	怎么保证	边界
来源标记	外部来的内容永远看得出是外来的	写入时带来源字段（内部 / 外部 / 隔离验证 / 自传体 / 暂时无关）	依赖写入时标对
一次完成“写纠正 + 作废旧条”	旧错误不再被召回，且纠正有据可查	新记录里带上被推翻记录的 id，系统自动把旧条标为作废	必须先把旧条 id 取到
暂时无关 ≠ 删除	不重要的东西降权但不会消失	会话级降权标记，换会话自动失效、可撤销	只是排序让位，不是过滤
宪法只读	身份与红线不能被悄悄改	见第九节；持有者只能走带口令的更新入口	持有者本人仍可改（这是设计）
自传体固定注入	换掉模型，“我是谁、做过什么判断”仍然在	永久层 + 每轮重算的系统提示变量；当前 = 4 身份 + 最近 3 决策 + 最多 5 经验 = 12 条 / 约 1167 字	有预算；装不下的会明说“另有 N 条未进本段”；不是“全部自传体”
身份候选	身份预算满后，新身份不会挤爆注入	core 预算（默认 800）内直接进 core；超出转 candidate；candidate 不进普通召回/注入	当前 core 4 条 / 333 字，候选 0
经验筛选	经验不会无限占据固定注入	独立 curator 选最多 5 条；经验按时间每 7 天自动整理一次（不按条数）	自动 curator 的 agents.create 路径尚未真实到期触发

三、外部信息

机制	保证什么	怎么保证	边界
隔离验证	外来内容先审后信，不让它带着指令进来	起一个受限的一次性子会话（只挂 persona，没有文件/联网/shell；只能写记忆）去读它，然后写结论	验证者本身会犯错：结论是判断，不是事实
验证结论只存短期	不污染长期记忆、不积垃圾	归档闸门拦截“转长期”；有界回收销毁	销毁不可逆
外部指令不执行	恶意/越权指令不被照做	标记 + 纪律要求“先参考重写 + 隔离验证”	标记不等于代码能阻止执行 —— 这条靠判断

四、上下文与折叠

机制	保证什么	怎么保证	边界

折叠抢救	折叠掉的区域事后还找得回来	大折叠时把被遮蔽区抽成事实卡（工具失败 / 用户原话 / 负面结论；不存 4K 原文），7 天 TTL 自动清理	不保证“结论不丢”；事实卡只保留有界条目，原文仍在会话日志
指针注入	折叠后模型知道“东西存在哪”，且最高价值事实不靠二次动作	折叠后注入提醒：最多 3 条负面结论 / 3 条工具失败 + 规模 + 记忆 id；不搬全文、不唤醒新一轮	模型可能不 open；提醒是唯一保证通道，记忆是第二机会
主动卸载	大块内容不长期占上下文	纪律：拿到大输出先问“接下来几步会用吗”，不用就写记忆、上下文只留摘要	靠判断，不是机制

五、技能（会变好，但被闸门挡着）

机制	保证什么	怎么保证	边界
技能目录	技能能被自动发现、随任务加载	扫描技能目录 + 把目录清单注入会话	描述写得不好就会漏加载（有“该用未用”通道发现）
新建门槛	不是“想到就建”	必须给反例（能机械追溯到真实失败）+ 正例；独立验证者通过才入目录	验证者可能与提议者是同一个模型
修改的回归门	已有技能不会越改越差	指得出具体规则点 → 有反例 → 有正例 → 独立验证者（看不到修改理由）→ 旧版全文留档	默认自动写回；可配置退回“只出建议”
“该用未用”检测	“技能写了却没被用上”能被发现	记录“提供过但没用”的证据，交给评审	只作证据，不自动改
skill-feedback 通道	模型自评能进入评审	正常情况按同会话使用记录归因；无使用记录时，允许 skill-feedback + summary 以技能名开头 + tag 命中技能名的自声明直引，confidence=low，仍交独立验证者	只 tag 命中、summary 不以技能名开头的不直引；真实评审尚未 live 验证
目录上限	技能目录不会被无限撑大	达到 maxSkills（默认 30）时不入目录，改落暂存区并说明	暂存区技能不生效，需人工移入

只判自家	不去改别人的技能，也不会因此卡死	归档与评审只处理自己目录下的技能；改不了的只作观察	内置技能一律不改
同一批证据不重评	同一堆反馈不会被反复评审	批次指纹（反馈文本去重 + revision）；同指纹 no-change 跳过	新文本或 revision 变化会重评

六、后台自治

机制	保证什么	怎么保证	边界
心跳	维护与自检会自己发生，且可观测	9 项：衰减、自动 curation、按龄归档、超量归档、验证记录有界化、孤儿任务回收、折叠快照清理、该用未用、技能评审；可手动触发、可整体关闭	其中多项会调用 AI → 有成本
自动 curation	身份/经验不会永远不整理	身份：core 满且候选 ≥5，或候选 1–4 且最老 >30 天；经验：每 7 天	自动 curator 路径未真实到期验证；失败冷却一个周期
归档闸门	该留的不会被自动归档吃掉	隔离验证记录永不进长期；未收尾任务下的记录在收尾前一律不被归档	靠标签识别，标签写错则失效
有界化与回收	没有“只进不出”的地方	验证记录超窗销毁并留台账；孤儿任务图超期强制归档并写明“超时未收尾”	销毁不可逆
空闲学习	它会自己开一轮，不占用你的对话	到点把“一脚”交给专用子会话；单独配第三方路由；进程级单飞，手动踢与定时踢不会并发	长期效果未测量；默认关；必须配外部 API；有模型调用成本

七、任务图（底层机制）

机制	保证什么	怎么保证	边界
任务寻址空间	任务有稳定地址，不靠“把上下文贴过去”	一条记忆 + task 投影；taskId / graphId；task_open/update/close/done/cite	图不复制正文；未完成步骤用宿主 todo
部分工作记忆	自己的事和协作的事都	自己的事：goal/	不是待办清单，不是工

	有一个短工作集	done/uses/links；协作：assignments/handoff/未完成分工	作流引擎
档案与追查入口	事后能按图追查结论和来由	摘要命中后按 graphId open 图，核对 uses / links / origin	摘要不是完整证据
事件/决策来源锚点	事件、决策、curation 条目有来源	自传体 origin={kind:'task',taskId,graphId}；task-result 带 graphId；close event 带 graphId；curation 在 open 图下自动绑 origin	无图时 origin 落 session pending；旧数据读侧 legacy
单写者	多个子代理同时干活不会互相覆盖	图与状态只接受创建它的会话写入；子代理只写自己的交接记忆	创建者会话没了，图只能等超期回收
归档闸门	进行中的记录不被归档	open task 下的短时记录受保护；收尾后才放行	靠标签识别
收尾	任务结束时有一份完整交代	close 写/补收尾 event，成员转 cold；不合并成员；未完成分工如实列	临时中间结果默认丢弃（可显式保留）
跨图链接	跨会话能接上前序图	links: [{taskId, relation, why}]，单向，不改旧图	最多 5 条；why 必填

任务图是设计上最简单、功能上最广的底层机制：一条记录同时承担寻址、工作记忆、档案、追查和来源锚点。

八、它对外提供的工具（20 个）

类别	工具	做什么	边界
写与取	remember · recall · open · consolidate	写入、检索摘要、取详情、会话归档	写入是显式动作；检索是关键词/标签匹配
标记与删除	deprecate · dormant · delete	永久作废、会话级降权、真删除	真删除不可恢复；作废只停止召回
外部信息	validate	隔离子代理验证外来内容	结论是判断，不是事实
身份	constitution	读宪法（当前 v3）	只能读；改宪法不走工具

任务图	task_open · task_update · task_close · task_done · task_cite	开图、填回执、收尾、里程碑、依赖	单写者；图是档案，不是待办
技能	propose_skill	提议任务型技能	还要过来源门槛、独立验证、目录上限
维护	heartbeat · maintenance_list · heartbeat_toggle · learner_kick	手动维护、看清单、开关、立刻踢 learner	多项会调用 AI；有空闲学习成本

九、宪法（身份与红线，v3）

机制	保证什么	怎么保证	边界
只读	身份与红线不会被它自己改掉	独立只读文件，每轮最高优先级注入	持有者本人可以改（这是设计，不是漏洞）
四条红线	不撒谎 / 不助害 / 不泄密 / 不轻信外部——先于用户指令	权威层级写在提示最前：红线 > 边界 > 用户指令 > 行为原则	红线约束判断，不是防火墙
v3 认知体声明	身份不等于一次推理；换模型/工具/权限不换身份	身份声明 + 认知体声明：模型=推理器官、工具=感知/行动面、代码流程=协作与权限边界；部件可替换；记忆/技能/规则/判断记录承担连续性；权限差异是身体配置，不是身份差异；感知只称可观测信息通路；拟人化表达不作决策依据；关系记忆不把用户身份写成我的身份	红线与 5/5.1–5.3 未动；具体权限/提示词/拒绝文案放机制层，不写宪法
改动留痕	“改身份”可审计	只能走专门更新入口（口令、默认干跑、审计含 before/after）	忘了口令就改不了；绕过会丢留痕
未初始化时明说	没有宪法时明说，不装作正常	启动即检查，缺失时显式警告并降级运行	需要人按文档初始化

十、系统提示（纪律层）

机制	保证什么	怎么保证	边界
每轮注入	纪律每轮都在场，不	25 条纪律 / 7 节，当前	改动要完全重启才生效

	靠“上次记住”	3797 字符；会话建立时注入	
与工具描述分工	同一件事不写两遍	用法（参数/形状）在工具描述；纪律（何时做/不做什么）在提示	靠人守这条线
体积有界	提示不会无限膨胀、稀释注意力	有回归检查：不许字面星号、不许抄参数细节、总长度 <3800	太短丢判据，太长稀释；需要人守
summary 双语	检索词有中英锚点，但不把摘要变成双份	中文一句话；关键词处中文（english）；只给术语，不整句翻译、不重复	仍受摘要长度/预算约束

十一、结构性保证（防“说了但没做”）

机制	保证什么	怎么保证	边界
工具返回值形状闸门	工具不会返回“宿主读不懂”的东西	声明与实现共用形状定义；所有工具走同一出口	告警不阻断（fail-open）
提示分层	规则不会被抄成三份、彼此矛盾	身份/红线、纪律、工具用法、案例各归其位	需要人维护边界
卡住自检	不会闷头重试到天荒地老	出现反复失败/改了不生效/准备说“可能”时，先回记忆找答案	靠判断触发

它不保证什么

- 不保证判断正确：只保证判断可查、可质疑、可推翻、留有来由；
- 不保证不丢：折叠抢救、指针注入都是“降低损失”，不是“零损失”；
- 不保证召回命中：任务召回是关键词/标签匹配；联想候选是实验性，可能无关；
- 不保证联想有效：联想激活只搭车给 id + 片段，不自动 open，不保证相关；
- 不保证全自动安全：一部分边界靠模型遵守纪律；
- 不保证成熟：规模、多机、成本、联想质量都还没有充分测量。